

Guia de Exposicion
Clasificacion del Riesgo de Inundacion
Provincia de Esmeraldas, Ecuador

Aprendizaje Automatico - Proyecto del Segundo Parcial
Grupo B - Universidad de Guayaquil

1. Contexto del Problema - Integrante 1

Ecuador es uno de los países más vulnerables a inundaciones en América Latina. Su ubicación en el trópico, la presencia de la Cordillera de los Andes y la influencia de corrientes oceánicas como El Niño generan condiciones que favorecen lluvias torrenciales e inundaciones recurrentes, especialmente en las regiones Costa y Amazonia.

Nuestra zona de estudio es la provincia de Esmeraldas, en la Costa norte del Ecuador. Presenta precipitación anual superior a 2,000 mm en la mayoría de sus parroquias, una altitud media de apenas 17 metros sobre el nivel del mar, y una densa red hidrográfica con ríos como el Esmeraldas, el Cayapas y el Santiago, además de numerosos esteros.

Según datos de la Secretaría de Gestión de Riesgos, en la última década se han registrado más de 30 eventos de inundación en la provincia, afectando a miles de familias y generando pérdidas económicas significativas en los sectores agrícola, vial y residencial.

Sin embargo, la mayoría de los estudios de riesgo existentes se basan únicamente en variables climáticas y geográficas, dejando de lado factores socioterritoriales como la calidad de la vivienda, el acceso a servicios básicos o la densidad poblacional.

Por eso, nuestro objetivo es construir un modelo de clasificación supervisada que integre ambas dimensiones --la física y la social-- para asignar a cada parroquia un nivel de riesgo de inundación: Bajo, Medio o Alto, utilizando únicamente datos abiertos y oficiales del Ecuador.

2. Datos y Construcción del Dataset - Integrante 2

Trabajamos con 19 variables predictoras provenientes de 4 fuentes oficiales.

Las 6 variables climáticas y geográficas fueron obtenidas del INAMHI y OpenStreetMap: precipitación anual, altitud media, pendiente del terreno, distancia a cuerpos de agua, densidad poblacional y porcentaje de área urbanizada.

Las 13 variables sociodemográficas provienen del Censo INEC 2022. Procesamos los microdatos de 4 tablas censales --Población, Hogar, Vivienda y Emigrantes-- y los agregamos a nivel de parroquia usando los códigos DPA. Obtenemos indicadores como edad media de la población, porcentaje de acceso a agua potable, alcantarillado, electricidad, calidad de paredes y techos, y personas por dormitorio como indicador de hacinamiento.

Esta última variable --personas por dormitorio-- es nuestra variable derivada, calculada como el cociente entre el total de personas en el hogar y el número de dormitorios, cumpliendo con el requisito del proyecto.

La variable objetivo la construimos nosotros mismos combinando dos fuentes del SNGRE: el mapa de zonas susceptibles a inundaciones y el registro histórico de eventos COE2. No usamos datasets con etiquetas predefinidas. La distribución final fue: Bajo 45.6%, Medio 36.6% y Alto 17.8%.

El dataset final contiene 320 registros correspondientes a 63 parroquias distribuidas en los 7 cantones de la provincia de Esmeraldas: Atacames, Eloy Alfaro, Esmeraldas, Muisne, Quinde, Rioverde y San Lorenzo.

3. Analisis Exploratorio - Integrante 3


En el analisis exploratorio identificamos patrones claros: las parroquias con riesgo alto tienen significativamente menor distancia a cuerpos de agua, menor pendiente del terreno y mayor precipitacion anual que las parroquias de riesgo bajo.

La matriz de correlacion confirmo estos hallazgos. La variable mas correlacionada con el riesgo es la distancia a cuerpos de agua, con una correlacion negativa de -0.48 , lo que significa que a menor distancia al agua, mayor es el riesgo de inundacion. Le sigue la pendiente del terreno con -0.31 : los terrenos planos acumulan agua mas facilmente. Y en tercer lugar la precipitacion anual con $+0.28$.


Estos resultados son fisicamente coherentes: una parroquia ubicada cerca de un rio, en un terreno plano y con alta pluviosidad tiene una probabilidad mucho mayor de inundarse que una parroquia en zona alta, alejada del agua y con menor precipitacion.

Las variables del INEC, aunque con correlaciones mas bajas, aportan informacion complementaria sobre la vulnerabilidad social. Por ejemplo, el hacinamiento del hogar tiene correlacion positiva con el riesgo, mientras que la calidad de la vivienda tiene correlacion negativa: a mejor calidad de vivienda, menor vulnerabilidad.

En cuanto a la calidad de los datos, no encontramos valores faltantes en las variables climaticas y geograficas. Los pocos valores nulos en las variables INEC corresponden a parroquias con poblacion muy dispersa y fueron imputados con valor cero, interpretando que eso indica ausencia del servicio. No se encontraron parroquias duplicadas.



Matriz de Correlacion entre Variables



4. Modelos y Resultados - Integrante 4


Entrenamos 5 modelos de clasificacion: Regresion Logistica como linea base, Arbol de Decision, Random Forest, SVM con kernel RBF y un Voting Classifier con votacion blanda que promedia las probabilidades de LR, RF y SVM. Todos los modelos usaron RobustScaler para normalizar las variables sin ser sensibles a valores atipicos. Dividimos el dataset en 70% para entrenamiento y 30% para prueba, con estratificacion para mantener la proporcion de clases.

Aplicamos GridSearchCV con validacion cruzada de 5 pliegues sobre Random Forest, explorando 4 hiperparametros: numero de arboles (100, 200, 300), profundidad maxima (5, 8, 12, None), minimo de muestras para dividir (2, 4, 6) y minimo de muestras por hoja (1, 2, 4). La mejor combinacion fue profundidad maxima de 5, 200 arboles, minimo de 2 muestras para dividir y 2 para hojas, con un F1-score de validacion cruzada de 0.7826.

En el conjunto de prueba, el Arbol de Decision obtuvo el mejor rendimiento con 85% de accuracy y 84.6% de F1-score ponderado. Sin embargo, el Random Forest optimizado tuvo mejor rendimiento en validacion cruzada (0.78 vs 0.75), lo que indica que generaliza mejor aunque haya obtenido menor puntaje en test.

Queremos destacar que la metrica mas relevante para la gestion del riesgo es el Recall, tambien conocido como sensibilidad, porque en contextos de desastres naturales es preferible clasificar una parroquia como riesgosa aunque no lo sea, generando un falso positivo, a no detectar una que si esta en riesgo y no tomar medidas de prevencion.

La curva ROC mostro un AUC promedio de 0.89 para las tres clases, con valores de 0.92 para la clase Bajo, 0.87 para Medio y 0.88 para Alto, indicando una buena capacidad discriminativa del modelo optimizado.



5. Features, App y Conclusiones - Integrante 5

El analisis de importancia de variables de Random Forest revelo que el factor mas determinante es la distancia a cuerpos de agua con un 23.3% de importancia relativa, seguido de la pendiente del terreno con 15.2% y la precipitacion anual con 14.3%. Estos tres factores confirman los fundamentos fisicos del riesgo de inundacion: a menor distancia al agua, menor pendiente y mayor precipitacion, mayor es el riesgo.

Las variables del censo INEC con mayor peso fueron el hacinamiento del hogar con 3.2%, personas por dormitorio con 2.7% y la edad media de la poblacion con aproximadamente 2%. Aunque su contribucion individual es menor que las variables geograficas, en conjunto demuestran que la vulnerabilidad social es un factor relevante que debe considerarse en la evaluacion integral del riesgo.


El modelo final fue empaquetado con Joblib e integrado en una aplicacion web Flask con mapa interactivo Leaflet, desplegada en Render y accesible en riesgo-inundacion.onrender.com. El mapa colorea las 63 parroquias segun su nivel de riesgo: rojo para riesgo alto, amarillo para medio y verde para bajo. Al pasar el mouse sobre una parroquia se muestra su nombre, canton y provincia, y al hacer clic se abre un popup con las probabilidades estimadas por el modelo. Tambien incluye un formulario de prediccion personalizada donde el usuario puede seleccionar una parroquia para usar sus datos censales reales o ingresar valores manualmente.

Como conclusiones principales: primero, demostramos que es posible construir un sistema de clasificacion de riesgo de inundacion usando solo datos abiertos y oficiales del Ecuador. Segundo, los arboles de decision ofrecen el mejor equilibrio entre precision, interpretabilidad y capacidad de generalizacion para este problema. Tercero, las tres variables mas influyentes --distancia al agua, pendiente y precipitacion-- confirman los fundamentos fisicos del riesgo de inundacion. Y cuarto, la inclusion de datos sociodemograficos del INEC, aunque con menor peso, demuestra que la vulnerabilidad social es un factor relevante.


Las principales limitaciones de este estudio son: el tamano muestral reducido de solo 63 parroquias en una sola provincia, lo que restringe la generalizacion de los resultados; el desbalanceo natural de la variable objetivo, con solo 18% de registros clasificados como Alto; y la ausencia de variables temporales como estacionalidad de las lluvias o cambio climatico. A futuro se podria ampliar el estudio a otras provincias del Ecuador, incorporar datos satelitales en tiempo real, y usar tecnicas de balanceo como SMOTE para mejorar la deteccion de la clase minoritaria.

Muchas gracias. Estamos listos para responder sus preguntas.

Importancia de Características - Random Forest



Curva de Aprendizaje - Random Forest Optimizado



[Insertar captura de pantalla de la app web aqui]