

Clasificación del Riesgo de Inundación por Parroquia en la Provincia de Esmeraldas, Ecuador

Proyecto del Segundo Parcial - Aprendizaje Automático

Julio 2026

Grupo B

Universidad de Guayaquil

Facultad de Ciencias Matemáticas y Físicas

1. Introduccion y Contextualizacion

Ecuador es uno de los paises de America Latina con mayor vulnerabilidad frente a eventos hidrometeorologicos extremos. Su ubicacion geografica, la presencia de la cordillera de los Andes y la influencia de corrientes oceanicas como El Nino generan condiciones que favorecen lluvias torrenciales e inundaciones recurrentes. La provincia de Esmeraldas, ubicada en la region Costa del Ecuador, es particularmente afectada por estos fenomenos debido a su alta pluviosidad (que supera los 2,000 mm anuales en muchas parroquias), su topografia de baja altitud (altitud media de 16.9 m) y la presencia de numerosos rios y esteros que atraviesan zonas densamente pobladas.

Segun datos de la Secretaria de Gestion de Riesgos (SNGRE), en la ultima decada se han registrado mas de 30 eventos de inundacion en la provincia, afectando a miles de familias y generando perdidas economicas significativas en los sectores agricola, vial y residencial. Sin embargo, la mayoría de los estudios de riesgo existentes se basan unicamente en variables climaticas y geograficas, dejando de lado factores socioterritoriales que determinan la vulnerabilidad de la poblacion.

El presente estudio propone un enfoque integral que combina variables climaticas (precipitacion anual), geograficas (altitud, pendiente, distancia a cuerpos de agua, densidad poblacional, area urbanizada) y sociodemograficas provenientes del Censo INEC 2022 (13 variables de poblacion, hogar, vivienda y emigrantes) para construir un modelo de clasificacion supervisada que asigne a cada parroquia una categoria de riesgo de inundacion: Bajo, Medio o Alto. Se disenaron e implementaron cinco modelos (Regresion Logistica, Arbol de Decision, Random Forest, SVM y Voting Classifier), se optimizaron hiperparametros mediante GridSearchCV y se evaluo su rendimiento con metricas estandar de clasificacion.

2. Descripcion de los Datos y su Origen

El dataset integrado contiene 320 registros correspondientes a 63 parroquias distribuidas en los 7 cantones de la provincia de Esmeraldas (Atacames, Eloy Alfaro, Esmeraldas, Muisne, Quinde, Rioverde y San Lorenzo). Cada registro representa una combinacion de parroquia y ano de observacion, con 19 variables predictoras y una variable objetivo.

Las variables climaticas y geograficas (6 en total) incluyen: precipitacion anual en mm (media de 2,167.53 mm), altitud media en metros (media de 16.90 m), pendiente promedio del terreno (media de 2.97 %), distancia media a rios y esteros en km (media de 1.14 km), densidad poblacional en hab/km² (media de 48.66) y porcentaje de superficie urbanizada (media de 5.01 %). Estas variables fueron obtenidas de fuentes oficiales como el INAMHI (Instituto Nacional de Meteorologia e Hidrologia) y OpenStreetMap.

Las variables sociodemograficas (13 en total) provienen del Censo INEC 2022 y se agrupan en cuatro categorias: poblacion (edad media, porcentaje de menores de 15 anos, mayores de 65 y hombres), hogar (porcentaje con acceso a agua publica, alcantarillado, electricidad y hacinamiento), vivienda (porcentaje con pared, techo y piso en buen estado, y personas por dormitorio como indicador derivado de hacinamiento) y emigrantes (total de emigrantes por parroquia). La inclusion de estas variables responde a la hipotesis de que la vulnerabilidad social agrava el impacto de las inundaciones, independientemente del peligro fisico.

La variable objetivo RIESGO_INUNDACION se construyo a partir de dos fuentes del SNGRE: el mapa de zonas susceptibles a inundaciones y el registro historico de eventos COE2. La asignacion siguio un criterio jerarquico: las parroquias con alta susceptibilidad Y eventos historicos registrados se etiquetaron como "Alto" (17.8 % de los registros); aquellas con susceptibilidad media O al menos un evento historico como "Medio" (36.6 %); y las de baja susceptibilidad sin eventos como "Bajo" (45.6 %).

3. Metodologia Aplicada

3.1 Analisis Exploratorio de Datos (EDA)

El analisis exploratorio revelo que no existen valores faltantes en las 6 variables climaticas/geograficas, mientras que las variables INEC presentaban algunos nulos en parroquias con poblacion dispersa, los cuales fueron imputados con valor cero (ausencia del servicio o dato no reportado). No se encontraron parroquias duplicadas. La matriz de correlacion mostro que las variables con mayor correlacion absoluta con el riesgo de inundacion son DISTANCIA_AGUA_KM, PENDIENTE_PCT y PRECIPITACION_ANUAL_MM, lo cual es consistente con la teoria hidrológica: a menor distancia al agua, menor pendiente y mayor precipitacion, mayor es el riesgo de inundacion.

3.2 Modelos de Clasificacion

Se dividió el dataset en entrenamiento (70 %) y prueba (30 %) con estratificación para preservar la proporción de clases. Todos los modelos utilizaron RobustScaler para normalizar las características sin ser sensibles a valores atípicos. Se implementaron y evaluaron cinco modelos:

1. Regresion Logistica (linea base) — modelo lineal con regularizacion L2.
2. Arbol de Decision — con profundidad maxima 5 y minimo de 5 muestras por division.
3. Random Forest — ensamble de 200 arboles con profundidad maxima 8.
4. SVM con kernel RBF — con C=10 y gamma=scale.
5. Voting Classifier (Soft) — ensamble que promedia las probabilidades de LR, RF y SVM.

3.3 Optimizacion de Hiperparametros

Se aplico GridSearchCV con validacion cruzada de 5 pliegues sobre Random Forest, explorando combinaciones de 4 hiperparametros: numero de arboles (100, 200, 300), profundidad maxima (5, 8, 12, None), minimo de muestras para dividir (2, 4, 6) y minimo de muestras por hoja (1, 2, 4). La metrica de optimizacion fue F1-score ponderado. Los mejores hiperparametros encontrados fueron: max_depth=5, min_samples_leaf=2, min_samples_split=2 y n_estimators=200, con un F1-score de validacion cruzada de 0.7826.

4. Resultados Obtenidos

La tabla siguiente resume el rendimiento de los cinco modelos en el conjunto de prueba:

Modelo	Accuracy	Precision	Recall	F1-Score
Decision Tree	85.00%	84.79%	85.00%	84.63%
Voting (Soft)	80.00%	80.00%	80.00%	80.00%
Random Forest	80.00%	78.00%	80.00%	78.63%
SVM (RBF)	70.00%	68.50%	70.00%	68.89%
Logistic Reg.	65.00%	68.23%	65.00%	65.89%

El Arbol de Decision obtuvo el mejor rendimiento global con un 85.00 % de accuracy y un F1-score ponderado de 84.63 %. Sin embargo, el modelo Random Forest optimizado mediante GridSearchCV alcanzo un F1-score de validacion cruzada de 0.7826, superior al del Arbol de Decision (0.7544), lo que indica mejor capacidad de generalizacion. El analisis de importancia de variables revelo que los tres factores mas influyentes son: distancia a cuerpos de agua (23.26 %), pendiente del terreno (15.19 %) y precipitacion anual (14.29 %). Las variables del censo INEC con mayor peso fueron hacinamiento del hogar (3.19 %), personas por dormitorio (2.71 %) y edad media de la poblacion (1.95 %).

La curva ROC mostro un AUC promedio de 0.89 para las tres clases, con valores de 0.92 para la clase Bajo, 0.87 para Medio y 0.88 para Alto, indicando una buena capacidad discriminativa del modelo optimizado. La matriz de confusion evidencio que los errores mas frecuentes ocurren entre las categorias adyacentes Medio y Alto, lo cual es admisible en un contexto de gestion de riesgo donde la precaucion es prioritaria.

5. Discusion y Limitaciones del Estudio

Los resultados demuestran que la integracion de datos sociodemograficos del INEC con variables climaticas y geograficas mejora la capacidad predictiva del riesgo de inundacion a nivel local. Mientras que los modelos lineales (Regresion Logistica) presentaron un rendimiento limitado (65 % de accuracy) debido a la complejidad no lineal de las relaciones entre las variables, los modelos basados en arboles capturaron mejor las interacciones entre factores fisicos y sociales.

El Arbol de Decision destaco por su simplicidad interpretativa, mientras que Random Forest ofrecio mayor robustez y capacidad de generalizacion. Sin embargo, se observo que el rendimiento en la clase "Alto" es sistematicamente menor (Recall de 0.33 en RF), lo cual se atribuye al desbalanceo natural de la variable objetivo (solo 17.8 % de registros clasificados como Alto) y al tamano reducido del conjunto de prueba (20 muestras). Este desbalanceo es una limitacion importante porque, en contextos de gestion de riesgo, la clase minoritaria (riesgo alto) es precisamente la mas critica de detectar.

Otras limitaciones del estudio incluyen: (1) el tamano muestral limitado a 63 parroquias de una sola provincia, lo que restringe la generalizacion de los resultados a otras regiones del Ecuador; (2) la dependencia de fuentes de datos oficiales que pueden tener sesgos de reporte y actualizacion; (3) la ausencia de variables temporales como la estacionalidad de las lluvias o el cambio climatico; y (4) la suposicion de que los datos INEC de 2022 siguen siendo representativos de la realidad actual. Futuras investigaciones podrian incorporar datos satelitales en tiempo real, proyecciones climaticas y un registro historico de eventos mas completo para mejorar la precision del modelo.

6. Conclusiones Finales

Este proyecto demostro que es posible construir un sistema de clasificacion del riesgo de inundacion a nivel de parroquia utilizando datos abiertos y oficiales del Ecuador, integrando variables climaticas, geograficas y sociodemograficas. Los modelos basados en arboles de decision ofrecen el mejor equilibrio entre precision, interpretabilidad y capacidad de generalizacion para este problema.

Las tres variables mas influyentes identificadas —distancia a cuerpos de agua, pendiente del terreno y precipitacion anual— confirman los fundamentos fisicos del riesgo de inundacion. Asimismo, la contribucion de las variables INEC, aunque menor en magnitud, demuestra que la vulnerabilidad social es un factor relevante que debe considerarse en la evaluacion integral del riesgo.

El modelo final se integro en una aplicacion web interactiva (Flask + Leaflet) desplegada en <https://riesgo-inundacion.onrender.com>, que permite visualizar el riesgo de inundacion en un mapa geopolitico de la provincia de Esmeraldas y realizar predicciones personalizadas para cualquier parroquia. Esta herramienta constituye un recurso practico para tomadores de decisiones en gestion de riesgos, planificacion territorial y proteccion civil, contribuyendo a la construccion de comunidades mas resilientes frente a desastres naturales en el Ecuador.